preLab 4차



순서

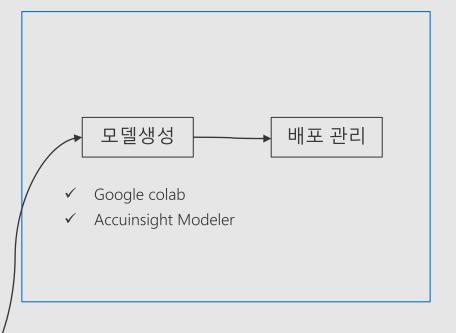
- ✓ 1. 개요
- ✓ 2. Supervised Learning
 - Class Imbalance
 - Modeling Using Accuinsight Modeler
 - 성능 평가

개요

Pipeline

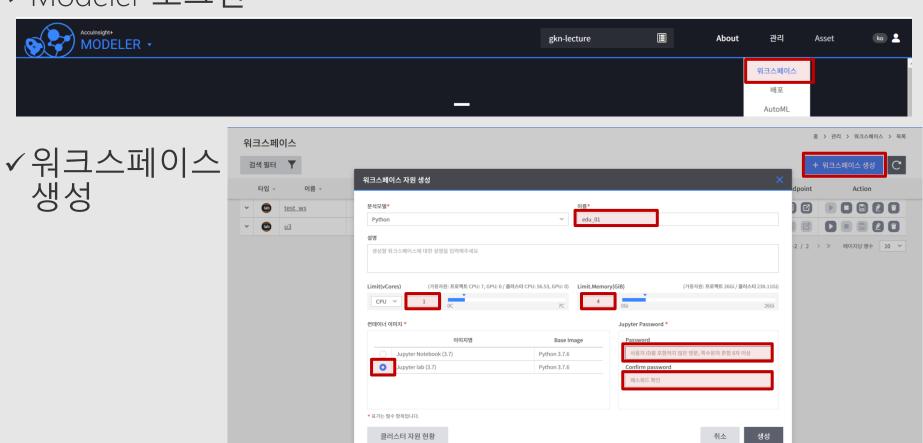
전처리 dropna drop HDFS 불러오기 HDFS 불러오기_tQYR drop empty data Drop nameOrig & nameDest filter filter filter select only type 2 and 5... isFraud = 0 outlier - newbalanceOrig filter isFraud = 1 upDown stratified unionAll stratified_a4F9 unionAll VaPd upDown_m15t S3 내보내기 HDFS 내보내기 S3 내보내기_I3e1 HDFS 내보내기_oSWn csv file

Modeler



개요 - 준비사항

✔ Modeler 로그인



개요

- ✓ Anomaly Detection이란,
 - Normal(정상) sample과 Abnormal(비정상, 이상치, 특이치) sample을 구별해 내는 문제
 - 제조 불량탐지, 금융 사기탐지, 의료 영상, Social Network 등 다양한 분야에서 응용 됨

✓ 해결하기 위한 방안

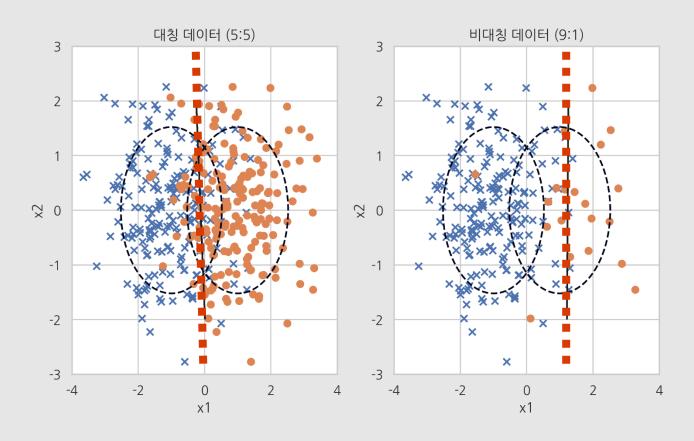
- Supervised Learning
- Semi-supervised Learning
- Unsupervised Learning

Supervised Learning

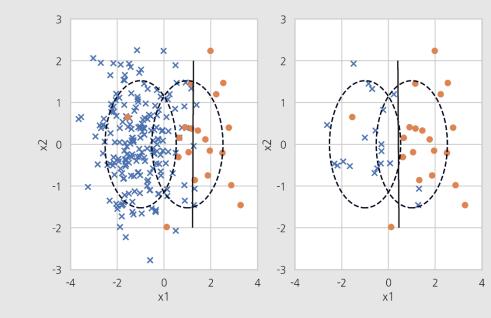
다룰 내용

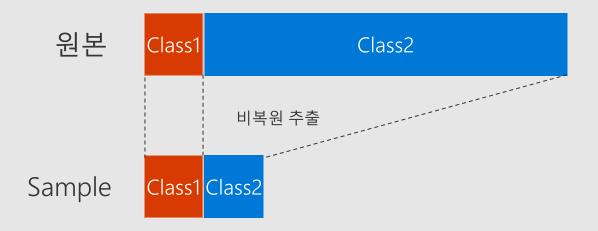
- ✓ Class Imbalance
- ✓ Modeling Using Accuinsight Modeler
- ✓ 성능 평가

✓왜 문제인가?

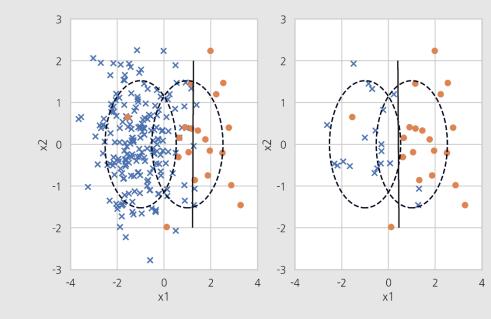


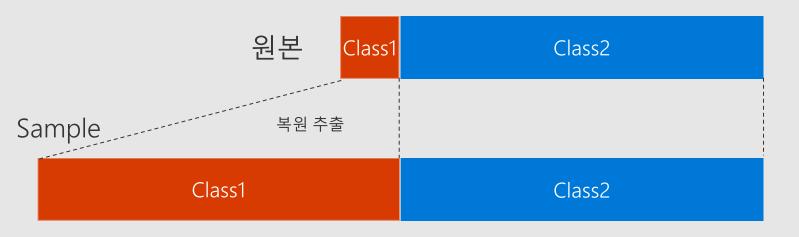
- ✓ Down Sampling
 - 다수 Class의 데이터를 소수 Class 수 만큼 random sampling



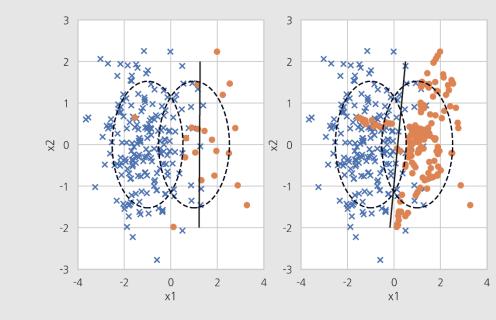


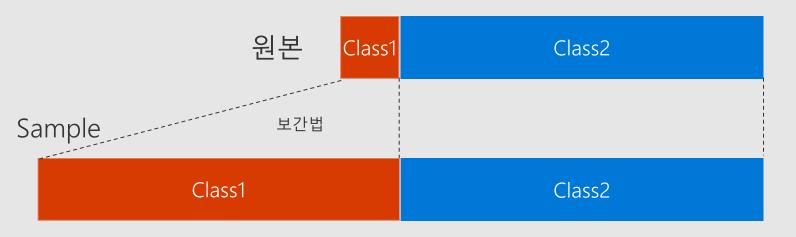
- ✓ Up Sampling
 - 소수 Class의 데이터를 다수 Class 수 만큼 random sampling(복원 추출)





- ✓ SMOTE(Synthetic Minority Oversampling TEchnique)
 - 기존 소수 샘플을 보간법(Interpolation)으로 새로운 데이터를 만들어 냄



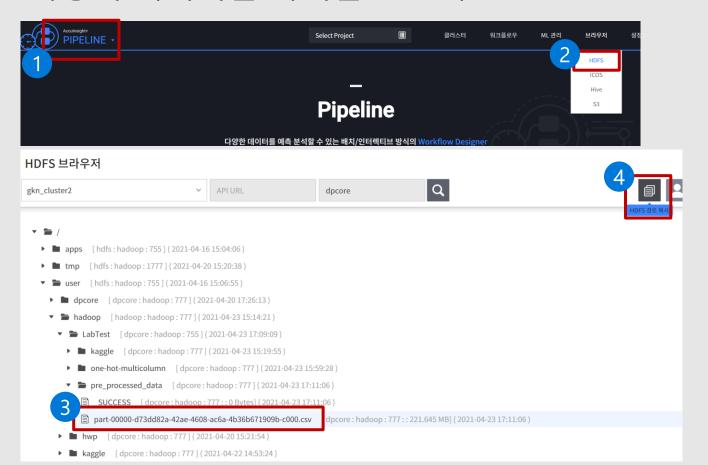


실습: Class Imbalance & 모델링 연습

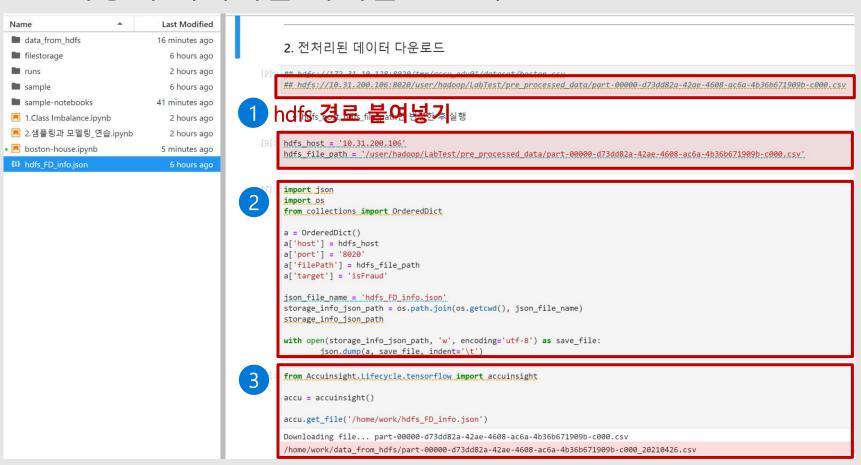
✓ 코드 구조

필요한 라이브러리 import				
데이터 불러오기				
데이터 준비				
모델링 로깅 설정				
모델링				

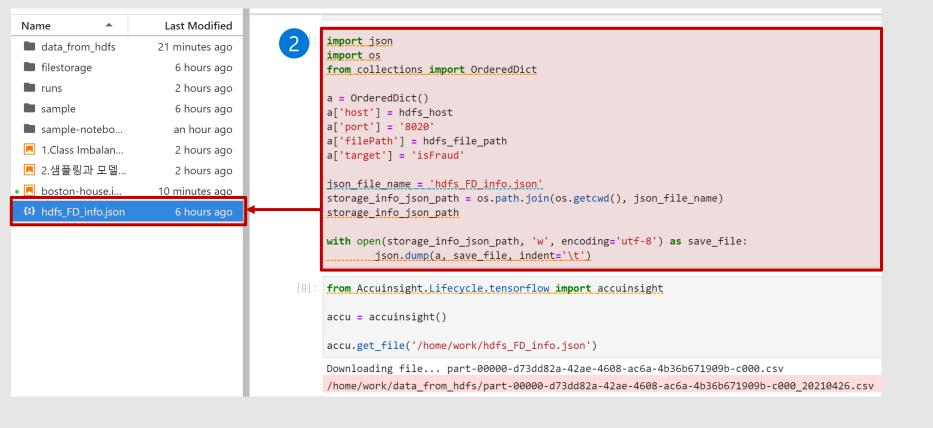
✔ 어떻게 데이터를 가져올 것인가?



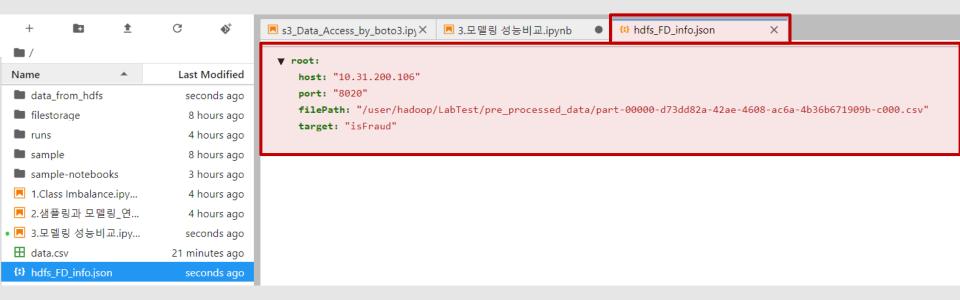
✔ 어떻게 데이터를 가져올 것인가?



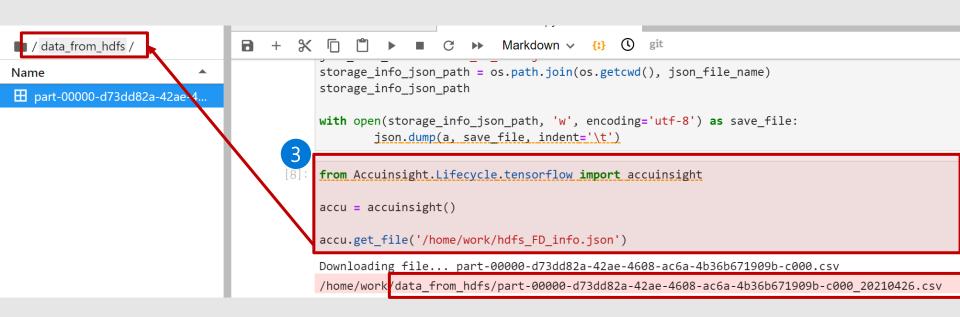
✓ 어떻게 데이터를 가져올 것인가?



✓ 어떻게 데이터를 가져올 것인가?

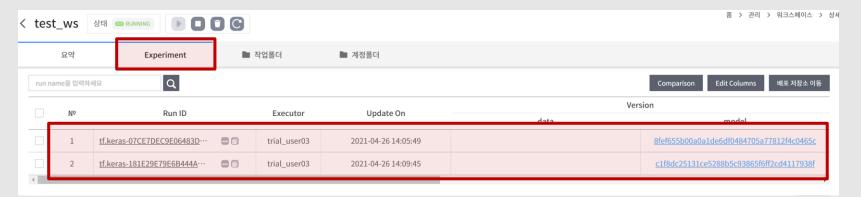


- ✔ 어떻게 데이터를 가져올 것인가?
 - 저장된 .json 파일을 기반으로 데이터 가져오기 : accu.get_file



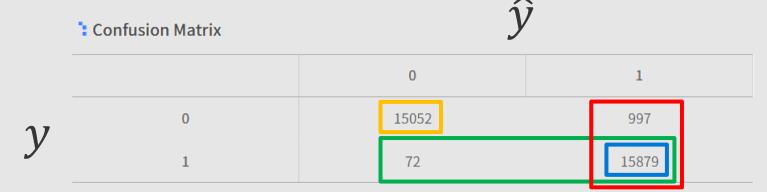
■ 파일 이름이 인식이 잘 안되는 문제가 있어서, 저장된 파일이름을 'data.csv'로 rename 합시다.

✓모델 저장과 성능 분석을 위한 로깅 설정



- ✓ Accuracy?
 - Accuracy : 전체 중에서 맞춘 비율
 - Class Imbalance 데이터에서 가장 주의해야 할 점!!!
 - Accuracy는 무시해야 할 수도...
- ✓ 그렇다면 Precision? Recall?
 - Precision 정밀도 : 사기거래라고 예측한 것들 중 맞춘 비율
 - Recall 재현율 : 실제로 사기거래 중 맞춘 비율
 - 무엇이 더 중요할까요?

✓ Confusion Matrix



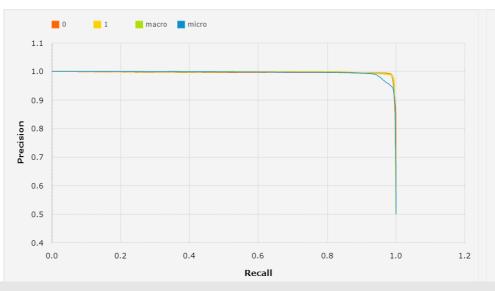
$$\checkmark accuracy = \frac{15052 + 15879}{total}$$

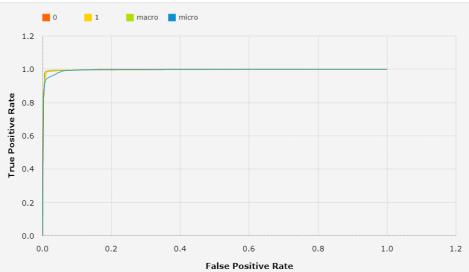
•
$$precision = \frac{15879}{72 + 15879}$$

$$recall = \frac{15879}{997 + 15879}$$

- ✓ Precision-Recall Curve
 - 0: 정상 거래 , 1: 사기 거래
 - macro : 산술평균, micro : 가중평균

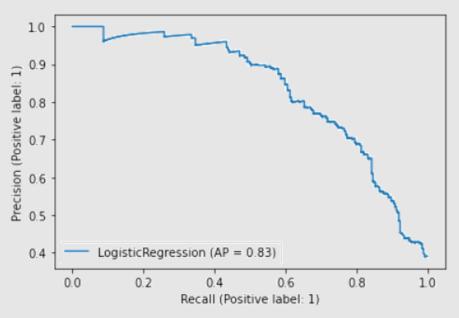
* Precision-Recall curve & ROC curve



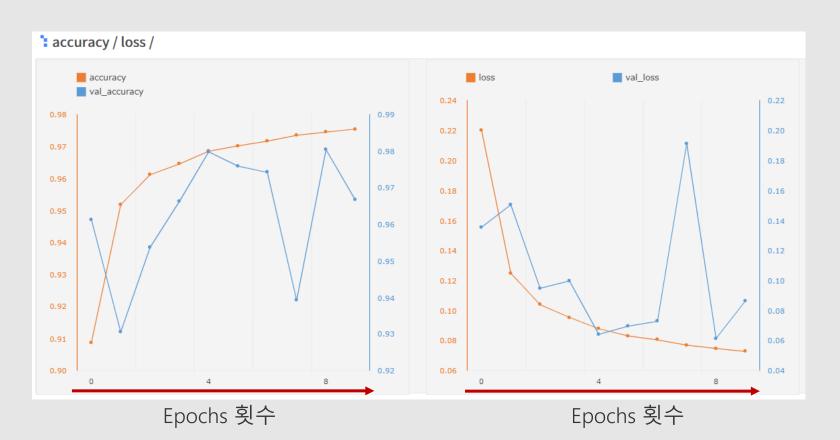


✓ Precision-Recall Curve



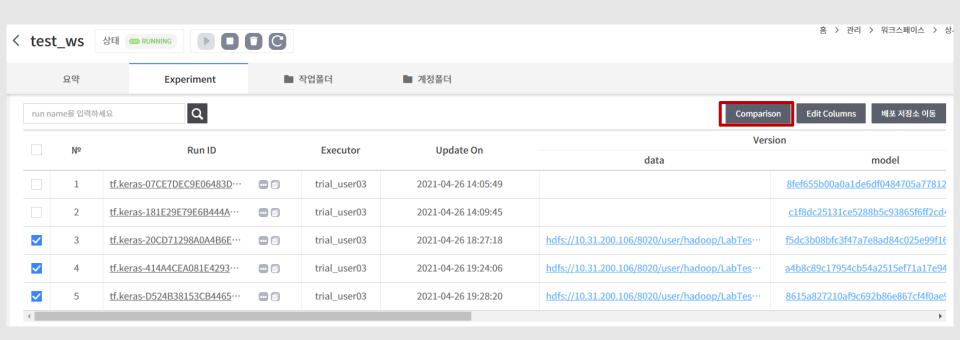


✓ Epochs 수를 더 늘리면?



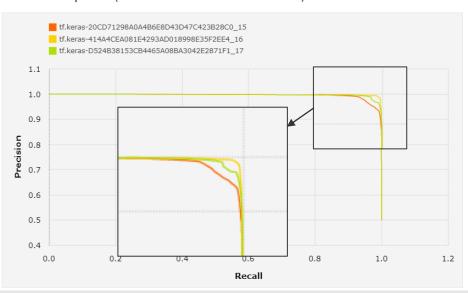
성능 평가 - 비교

✓로깅 된 모델들을 선택(최대 10개까지 가능)한 후, Comparision



성능 평가 - 비교

Model Comparison(Precision-Recall curve & ROC curve)





Mertrics

Model Version	AUC	Precision	Recall	F1-score
tf.keras-20CD71298A0A4B6E8D43D47C423B28C0_15	0.9957880624999976	0.9958331841897203	0.96659375	0.96659375
tf.keras-414A4CEA081E4293AD018998E35F2EE4_16	0.9976663749999992	0.9976494484769797	0.9895625	0.9895625
tf.keras-D524B38153CB4465A08BA3042E2871F1_17	0.997368499999988	0.9973862921872153	0.9770625	0.9770625

* AUC : area under curve ,

* F1-score : Precision과 Recall의 조화평균

실습

- ✔다양한 파라미터 값으로 최소 5개 이상의 모델을 생성합니다.
- ✓ Accuinsight Modeler에서 Experiment로 이동 > 모델들의 성능을 비교해 봅시다.
- ✓ 주의사항: 모델 생성(.fit) 할 때 마다, 사전에 반드시 accu.autolog()를 실행해 줘야 로그가 남습니다.
- ✓ 5개 이상의 모델 성능 비교에 대해서 스크린샷을 28일 18시까지 보내주셔야 합니다~!!!!!

- ✓ 그러나 우리는 항상 Machine Learning Metric을 Business Metric으로 변환해서 평가할 수 있어야 한다.
- ✓ 그것이 우리가 지금 이 일을 하는 목적!